# 本科毕业论文

# 面向持久内存的键值存储系统设计与实现

基于 xv6 教学操作系统的 PMFS-KV 与可机器判定契约

专业名称：计算机科学与技术

学生姓名：（姓名）

指导教师：（指导教师）

所在学院：（学院）

完成日期：二〇二六年六月

（按学校正式封面模板替换本页）

# 摘　要

持久内存（Persistent Memory, PMEM）以字节寻址方式提供近似 DRAM 的访问延迟，同时具备掉电后数据保留能力，为操作系统存储子系统提出了不同于块设备日志文件系统的一致性模型与工程验收问题。教学操作系统 xv6 以 virtio 块设备与日志型文件系统作为根文件系统，适合讲授经典 UNIX 语义，但难以直接承载「可机器判定的崩溃与掉电语义」这一工程化目标。

本文在 xv6-riscv 上设计并实现并行于根文件系统的字节寻址键值存储引擎 **PMFS-KV**，而非替换完整 POSIX 文件层。系统采用双槽超级块提交、不可变 run 与可观测的 B1/B2/B3 重写路径，并引入量化索引与查询缓存以支撑查找。物理后端支持三种模式：静态仿真缓冲（EMUL）、物理窗口映射（MAP），以及基于 QEMU `memory-backend-file` 的文件级掉电实验（PMEM2）。

本文的核心贡献不在于「再实现一套双槽 PMEM-KV」，而在于在教学操作系统上构建**可机器判定的崩溃与掉电契约套件**：统一串口阶段码 `ONBOX_PMFS_*`，配合宿主脚本实现 `make contract`、`contract-pmem`、`contract-pmem2` 的一行判定与 CI 复现。实验在故意不对等的 API 对比下给出量级延迟与写放大随负载规模 $N$ 的变化，并说明 EMUL/MAP 同量级时瓶颈主要位于软件提交路径。实现过程中的启动栈溢出、`rdcycle` 权限、NUMA 内存尺寸不匹配等踩坑均予记录，以增强可复核性。

**关键词：**持久内存；键值存储；崩溃一致性；写放大；xv6；契约测试

# Abstract

Persistent memory (PMEM) offers byte-addressable access with near-DRAM latency while retaining data across power loss, which challenges the consistency model and acceptance methodology of OS storage stacks built around block devices. The teaching OS xv6 uses a virtio block device and a log-structured file system as its root file system; it is excellent for classic UNIX semantics but does not by itself provide machine-checkable crash and power-loss contracts.

This thesis designs and implements **PMFS-KV**, a byte-addressable key–value engine that runs *alongside* the xv6 root file system rather than replacing the POSIX inode layer. The storage core uses dual-slot superblocks, immutable runs, and an observable B1/B2/B3 rewrite path, plus a quantized index with query cache. Three backends are supported: an in-DRAM emulation buffer (EMUL), a mapped physical window (MAP), and a QEMU file-backed power-loss setup (PMEM2).

The distinctive contribution is a **machine-checkable crash/power-loss contract suite** on a teaching OS: serial stage lines `ONBOX_PMFS_*` and host scripts that decide pass/fail by grepping a single line under `make contract`, `contract-pmem`, and `contract-pmem2`. Benchmarks report order-of-magnitude latency and write amplification versus $N$ under intentionally unequal APIs, and show that EMUL and MAP lie in the same order of magnitude, pointing to software commit paths as the main bottleneck. Implementation pitfalls (boot-stack overflow, `rdcycle` privilege, NUMA size mismatch, etc.) are documented for reproducibility.

**Keywords:** persistent memory; key–value store; crash consistency; write amplification; xv6; contract testing

# 目录

**摘要** **I**

**Abstract** **II**

**第一章 绪论** **1**
1.1 研究背景 . . . . . 1
1.2 问题陈述 . . . . . 1
1.3 研究内容与目标 . . . . . 1
1.4 主要贡献 . . . . . 2
1.5 论文结构 . . . . . 2

**第二章 相关工作** **3**
2.1 教学操作系统中的块文件系统 . . . . . 3
2.2 持久内存文件系统与编程模型 . . . . . 3
2.3 日志结构与近似索引 . . . . . 3
2.4 作者前序原生工作与工程契约手法 . . . . . 3
2.5 本文定位小结 . . . . . 3

**第三章 系统设计** **5**
3.1 产品形态与非目标 . . . . . 5
3.2 地址空间与三种后端 . . . . . 5
3.3 软件分层 . . . . . 5
3.4 崩溃一致性契约（设计层） . . . . . 6
3.5 写放大与可观测性 . . . . . 6
3.6 性能对比的设计意图 . . . . . 6

**第四章 系统实现** **7**
4.1 模块与代码组织 . . . . . 7
4.2 双槽超级块与 seal . . . . . 7
4.3 索引路径 . . . . . 7
4.4 ONBOX_PMFS 契约套件 . . . . . 7
4.5 计时与评测脚手架 . . . . . 8
4.6 与 CI 的衔接 . . . . . 8

**第五章 实验与分析** **9**
5.1 实验环境 . . . . . 9

5.2 功能、崩溃与掉电（尖刺证据） . . . . . 9
5.3 性能：随 $N$ 变化的延迟 . . . . . 9
5.4 写放大 . . . . . 11
5.5 MAP 与 EMUL 对照 . . . . . 11
5.6 实现难点与失败史 . . . . . 11
5.7 局限与威胁效度 . . . . . 12
5.8 本章小结 . . . . . 12

**第六章 结论与展望** **13**
6.1 工作总结 . . . . . 13
6.2 不足 . . . . . 13
6.3 展望 . . . . . 13

**附录 A 复现命令与扩展说明** **16**
A.1 一键契约与评测 . . . . . 16
A.2 关于真 NVDIMM . . . . . 16
A.3 论文 PDF 编译 . . . . . 16

**致谢** **17**

# 第 1 章　绪论

## 1.1　研究背景

操作系统存储子系统长期以块设备为中心：文件内容经缓冲缓存、日志与块 I/O 栈落盘，崩溃一致性依赖有序刷写与检查点。教学操作系统 xv6 [3] 以 virtio-blk 与日志型文件系统讲授这一经典路径，语义清晰、代码可阅读，但延迟受块设备与元数据更新约束，且难以自然表达字节寻址持久内存（Persistent Memory, PMEM）上的提交与掉电语义。

PMEM 以字节寻址提供近似 DRAM 的访问延迟，并在掉电后保留数据 [6]。学术界与工业界已出现面向 PMEM 的文件系统与编程模型, 如 PMFS [4]、NOVA [11]、BPFS [2]、Mnemosyne [10] 等。它们多面向通用或接近生产的 Linux 环境；将完整 POSIX 文件层移植进 xv6 既超出本科毕设合理体量，也易掩盖「如何验收崩溃正确性」这一更尖锐的工程问题。

## 1.2　问题陈述

本文关注三个相互耦合的问题：

1. **形态选择：**在 xv6 上是替换根文件系统，还是提供并行的字节寻址键值（KV）引擎？完整 inode/目录层成本高，且与「验证提交与掉电」目标不对齐。
2. **一致性模型：**双槽超级块、不可变 run、批量 seal 提交如何保证「未提交不可见、半写活动槽可检测」?
3. **验收方法：**如何让崩溃与掉电语义**可机器判定**（串口一行、宿主脚本、CI），而非仅靠人工读日志?

## 1.3　研究内容与目标

本文设计并实现 **PMFS-KV**：并行于 virtio 根文件系统的 PMEM 键值引擎，提供 `pmfs_put/get/seal/stat` 系统调用；物理后端支持 EMUL、MAP 与 PMEM2 三种模式。研究目标可概括为：

- 在教学 OS 上落地可观测的存储核（双槽 SB、B1/B2/B3、写放大计量）；
- 建立 `ONBOX_PMFS_*` 契约套件与 `make contract*` 验收门；
- 在明确「API 不对等」前提下给出延迟与写放大随负载规模 $N$ 的实验叙述，并记录可复核踩坑。

## 1.4 主要贡献

对照相关工作与作者前序原生项目（FCS / Aurora），本文贡献收敛为一条尖刺与两条支撑柱 [13, 12, 14]：

**尖刺（C1）**
教学 OS 上可机器判定的崩溃与掉电契约套件：阶段码表 + 宿主脚本 + CI。

**系统柱（C2）**
xv6 内双槽存储核与可观测 B3、索引自 run 重建、`pmfs_stat` 写放大。

**实验柱（C3）**
PMEM2 文件后端杀启掉电一行过，作为尖刺在掉电场景上的实例化。

主动不宣称的内容包括：完整内核 VFS、真 NVDIMM 主线化、将 FCS/Aurora 源码并入库。

## 1.5 论文结构

第 二 章综述相关工作与借鉴边界；第 三 章给出总体设计；第 四 章描述实现与契约；第 五 章报告实验、性能图与踩坑；第 六 章总结并展望。附录给出真 NVDIMM 与复现命令。

# 第 2 章　相关工作

## 2.1　教学操作系统中的块文件系统

xv6 [3] 的 `fs+log` 路径以 inode、目录项、位图与日志检查点保证崩溃后可恢复。该设计适合教学，但其 I/O 路径绑定 virtio 块设备与 bio，元数据更新成本随「每文件一次 create/write/sync」近似线性增长。本文将该路径作为对照基线，**仍保留为根文件系统**，不主张用 PMFS-KV 替换日常用户程序的文件语义。

## 2.2　持久内存文件系统与编程模型

PMFS [4] 与 NOVA [11] 面向 PMEM 提供文件语义；Strata [5] 等探索跨介质分层。BPFS [2]、Mnemosyne [10] 强调细粒度持久与编程抽象。上述工作的问题域是通用或接近生产的 PMEM 文件/运行时。本文取其「字节寻址 + 显式持久」动机，但产品形态收敛为 **KV 子集**，体量与 xv6 教学代码库匹配。

## 2.3　日志结构与近似索引

LSM 类结构 [9] 与 Bloom 过滤器 [1] 广泛用于写入友好与存在性过滤。本文 run 不可变、批量 seal 与 Bloom/fence 属于同一设计家族，但实现服务于教学内核约束（页粒度、有限段数、无用户态复杂压缩管线）。

## 2.4　作者前序原生工作与工程契约手法

作者前序原生项目 **FCS** [13] 提供嵌入式耐久 KV 的设计约束：双槽超级块、不可变 run、B1/B2/B3 与写放大计量；**Aurora** [12] 提供键量化、二值 posting 与查询 LRU 等索引约束。二者代码不并入本仓库，xv6 侧为 C 语言自研重写，以防「移植题」误读。

工程验收上，作者在其他内核工程中使用过 `ONBOX_*` 串口契约手法 [14]；本课题将其重写为服务存储语义的 `ONBOX_PMFS_*` 阶段/失败码，使崩溃与掉电可被 `grep` 与 CI 判定。

## 2.5　本文定位小结

防「移植题」的标准表述：数据结构思想可追溯前序约束，但验收资产（契约套件）与 xv6 内实现为本课题自有贡献。

表 2.1　相关工作与本文关系

| 工作 | 问题域 | 与本文 |
| --- | --- | --- |
| xv6 fs+log | 教学块 FS | 对照基线；仍作根 FS |
| Linux PMFS/NOVA 等 | PMEM 文件 FS | 动机参考；本文为 KV 子集 |
| 作者 FCS / Aurora | 耐久引擎与索引（原生前序） | 约束下沉；代码自研重写 |
| cxc-os 类契约 | 串口阶段验收 | 手法参考；码表重写 |
| **本文 PMFS-KV** | 教学 OS 上 PMEM-KV + 契约套件 | **尖刺 = 可机器判定崩溃/掉电** |

# 第 3 章　系统设计

## 3.1　产品形态与非目标

PMFS-KV 的产品形态是：**并行于 virtio 根文件系统的字节寻址键值引擎**。用户态通过系统调用 `pmfs_put`、`pmfs_get`、`pmfs_seal`、`pmfs_stat` 访问；可选薄层 `pmfs_posix` 仅做路径 hash→KV 的 shim，不升格为内核 VFS。

明确非目标：完整 inode/目录文件系统；真物理 NVDIMM 作为主线依赖；将 FC-S/Aurora 源码树并入库。

## 3.2　地址空间与三种后端

内核约定物理/虚拟布局（相对地址）：

Listing 3.1　PMEM 窗口相对布局示意

```
KERNBASE  ---------- 0x80000000
  kernel + user pages（易失 DRAM）
PHYSTOP   ---------- KERNBASE + 128MiB
PMEMBASE  ---------- PHYSTOP
  字节寻址持久区（双槽 SB / 数据 run）
PMEMEND   ---------- PMEMBASE + 32MiB
```

表 3.1　三种物理后端

| 模式 | 构建 | 运行要点 |
|---|---|---|
| EMUL | 默认 | $-m$ 128M，2 MiB 静态缓冲 |
| MAP | `-DPMEM_MAP` | $-m$ 160M，映射 `[PMEMBASE,PMEMEND)` |
| PMEM2 | `-DPMEM_MAP` | `memory-backend-file,share=on` 杀启 |

EMUL 用于算法与契约快速回归，不代表真 NVDIMM 延迟；MAP/PMEM2 验证窗口级映射与文件后端掉电存活（QEMU 文件内存后端配置见官方文档 [7]）。

## 3.3　软件分层

自上而下：

1. 用户 API：`put/get/seal/stat`；
2. `pmalgo`：内存表 → 不可变 run、B1/B2/B3、写放大计量；
3. `pmindex`：量化键、posting、查询 LRU（qcache）；

4. `pmfs`：双槽超级块与 commit；
5. `pmdev`/`pmem_persist`：落 EMUL 或 MAP 窗口。

盘上布局：页 0/1 为超级块双槽；页 $\geq 2$ 为不可变 run 数据页。无 inode 表。

## 3.4 崩溃一致性契约（设计层）

提交以 `seal` 为显式边界：批量 `put` 进入内存表后，`seal` 将 run 持久化并原子翻转活动超级块槽位（epoch + 校验）。设计保证：

- 半写活动槽在挂载时可检测并回退；
- 未提交数据对 `get` 不可见；
- 索引可自 run 重建，避免单独持久索引与数据不一致。

契约的机器判定形式在第 四 章展开：串口阶段码与宿主脚本。

## 3.5 写放大与可观测性

定义

$$\text{wa_x100} = \frac{\text{phys} \times 100}{\text{logical}},$$

其中 logical 为用户 payload 字节，phys 为整页写入（对齐、run、B3 重写）。小 value（如 8 B）相对 4 KiB 页必然放大；该放大与 xv6 日志放大**不同源**，论文中分开叙述。

## 3.6 性能对比的设计意图

实验故意对比异构路径：PMFS-KV 为 $N$ 次 `put` + 一次 `seal` + $N$ 次 `get`；xv6 为每键一次小文件 `create/write` + `sync`。目的是说明「避免 virtio 日志与目录更新」的**量级**差异，而非宣称同等 POSIX 文件 API 下的绝对加速比。

# 第 4 章　系统实现

## 4.1　模块与代码组织

实现基于 xv6-riscv，主要新增/修改模块包括：`kernel/pmem.c`（后端与 persist）、`kernel/pmfs.c`(双槽 SB 与挂载)、`kernel/pmalgo.c`(run/B 路径)、`kernel/pmindex.c`(量化索引)、`kernel/pmcontract.c`（自测与串口契约）、`kernel/syspmfs.c`（系统调用）、以及用户态 `_pmfs_probe`/`_pmfs_bench`/`_pmfs_posix`。构建目标区分默认内核与 `kernel-pmem`（`-DPMEM_MAP`）。

## 4.2　双槽超级块与 seal

活动槽与镜像槽交替提交。`seal` 路径将当前 mem 表固化为 run 页，更新超级块字段（epoch、校验、run 元数据），再经 `pmem_persist` 落后端。挂载时选择校验合法且 epoch 较新的槽；半写损坏触发 `CRASH` 相关失败码并回退。

B3 路径对需重写的页做真页写入，而非仅更新指针；`pmfs_stat` 导出 logical/phys 与 wa_x100，使写放大可在用户态契约行中观测。

## 4.3　索引路径

索引采用键量化与 posting 结构，查询侧维护 LRU 缓存（qcache）。索引可自 run 重建：在挂载或自测阶段扫描已提交 run，避免「索引已更新而数据未提交」的窗口。该约束来自 Aurora 前序设计 [12]，实现为 xv6 C 重写。

## 4.4　ONBOX_PMFS 契约套件

所有契约行必须可被 `grep / tools/contract_pmfs.py` 匹配。

**成功行**

`ONBOX_PMFS_⟨STAGE⟩_PASS` + 空格分隔 `key=value`

**失败行**

`ONBOX_PMFS_⟨STAGE⟩_FAIL stage=... code=...`

**总闸**

必过子集全部成功后打印 `ONBOX_PMFS_PASS`

必过子集（EMUL / 默认 `make qemu`）：`PMEM0`、`MOUNT`、`STORE`、`INDEX`、`ALGO`、`CRASH`，然后总闸。MAP 模式额外要求 `PMEM0 mode=MAP` 与 `PMEM1`。PMEM2 杀启后必须出现

```
ONBOX_PMFS_PMEM2_PASS persist=ok
```

脚本成功时再印 ONBOX_PMFS_PMEM2_CONTRACT_PASS boots=2。

用户态：_pmfs_probe → SYSCALL_PASS；_pmfs_bench [N] → BENCH_PASS（含 wa_x100）；_pmfs_posix → POSIX_PASS（薄 shim，不升主线）。

## 4.5 计时与评测脚手架

用户态原调用 cycles() 依赖 rdcycle；在未开放 mcounteren.CY 时会触发非法指令（计数器与特权态约束见 RISC-V 特权规范 [8]）。实现将 sys_cycles 改为已允许的 r_time()，文档明确其为**相对时间单位**，不作墙钟微秒解读。评测脚本对每个 $N$ 执行 5 次 trial 取中位数，并等待契约行字段齐全后再杀 QEMU，避免截断解析。

## 4.6 与 CI 的衔接

持续集成挂接 usertests 与契约目标，使回归不以人工读完整串口日志为前提。尖刺价值正在于此：正确性与掉电语义「grep 一行即可判过」。

# 第 5 章　实验与分析

## 5.1　实验环境

表 5.1　实验环境

| 项 | 配置 |
|---|---|
| 基线 | xv6-riscv（课题分支） |
| 模拟器 | QEMU `virt`，`CPUS=1` |
| 后端 | EMUL / MAP / PMEM2（见第 三 章） |
| 回归 | `usertests`、契约目标（CI） |
| 计时 | 内核 `r_time()` 相对单位；每 $N$ 取 5 trial 中位数 |

数据复现：`make bench-sweep` 回填 `docs/BENCH.md`；契约：`make contract`、`contract-pmem`、`contract-pmem2`。

## 5.2　功能、崩溃与掉电（尖刺证据）

表 5.2　契约验收用例

| 用例 | 命令 | 期望 | 说明 |
|---|---|---|---|
| 总闸 | `make contract` | `ONBOX_PMFS_PASS` | EMUL 必过子集 |
| MAP | `make contract-pmem` | `mode=MAP`+PMEM1 | 窗口映射 |
| 掉电 | `make contract-pmem2` | `PMEM2_PASS` | 文件后端杀启 |
| CRASH | 内嵌自测 | `CRASH_PASS` | 半写/未提交 |
| POSIX shim | `pmfs_posix` | `POSIX_PASS` | 不升主线 |

分析：契约套件使「完好 SB / 未提交不可见 / 窗口 persist」可机器判定；相对仅演示双槽结构，这是方法学差异，构成本文尖刺。

## 5.3　性能：随 $N$ 变化的延迟

对比路径故意不对等（表 5.3）。ratio$\gg 1$ 主要反映避免 virtio 日志与目录更新的架构差，**不可**解读为同等 POSIX 文件 API 下的千倍加速。

观察：(1) xv6 随 $N$ 近似线性；(2) PMFS 以一次 seal 摊销提交, ratio 通常仍 $\gg 1$；(3) 论文结论写作**量级优势 + 边界**。

表 5.3　故意不对等的对比维度

| 维度 | PMFS-KV | xv6 fs+log |
|---|---|---|
| API | `put`×$N$ + 1×`seal` + `get`×$N$ | `open/create+write(8B)`×$N$ + `sync` |
| 持久语义 | 双槽 SB 提交点 | 块日志检查点 |
| I/O 栈 | 字节寻址窗口 / EMUL | virtio-blk + bio + log |
| 元数据 | 无目录/inode | 目录项 + inode + 位图 |

表 5.4　EMUL 下随 $N$ 变化的中位数（5 trial）

| $N$ | median_pmfs | median_xv6 | ratio×100 | wa_x100 | logical | phys |
|---|---|---|---|---|---|---|
| 8 | 9206 | 7408714 | 80477 | 8432 | 340 | 28672 |
| 16 | 12168 | 16440967 | 135116 | 4344 | 660 | 28672 |
| 32 | 35830 | 33130730 | 92466 | 2205 | 1300 | 28672 |

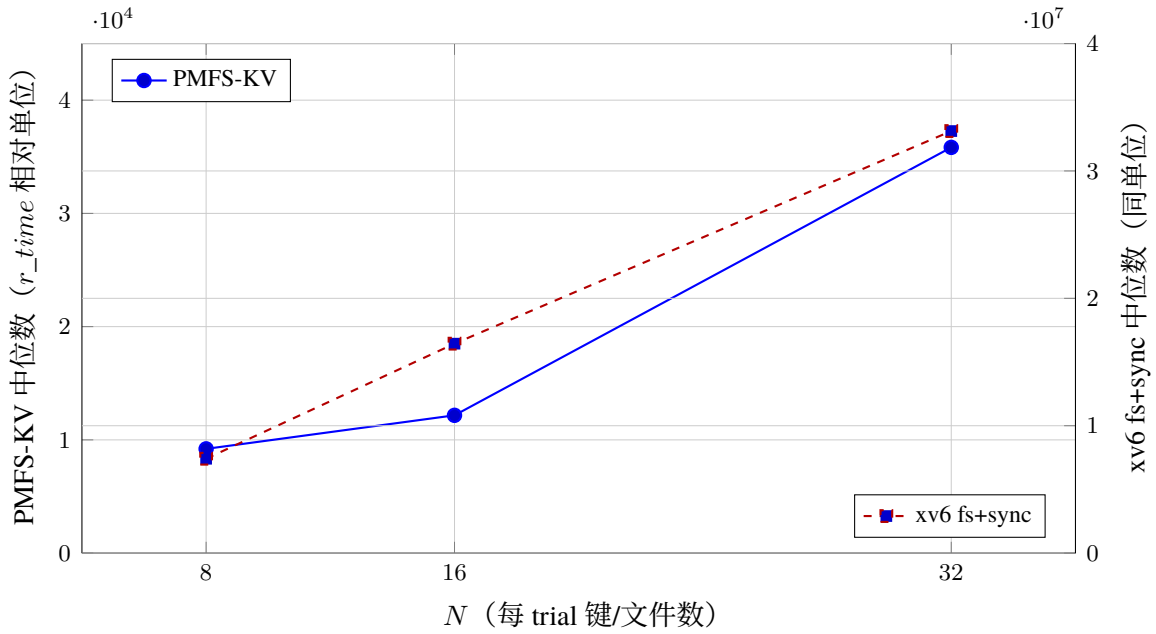



图 5.1　随 $N$ 变化的中位数延迟（EMUL，5 trial）。左右纵轴分属两条路径；对比动机为架构量级差异，API 故意不对等。

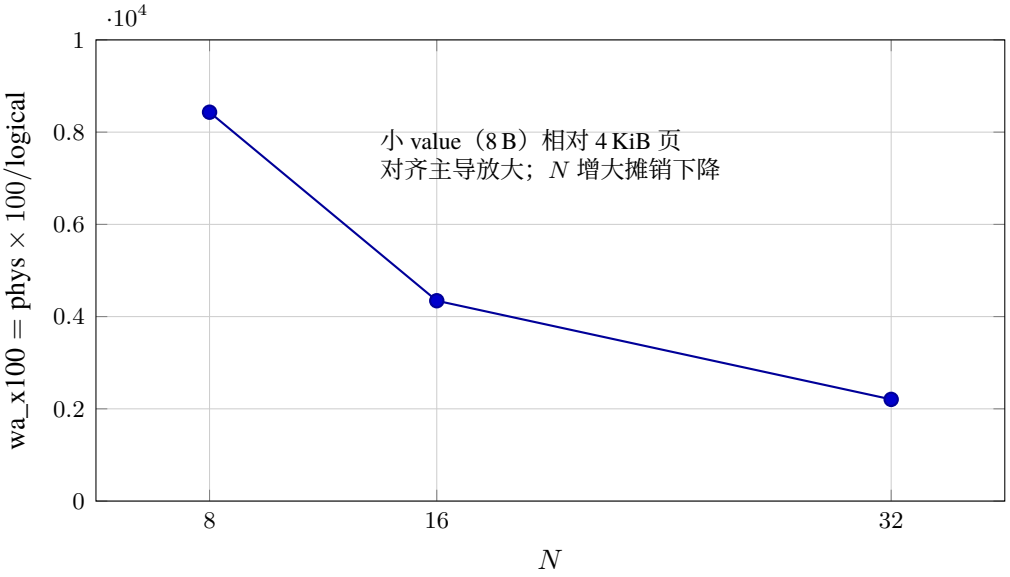



图 5.2　写放大 wa_x100 随 $N$ 变化（EMUL）。高放大属页粒度预期，与 xv6 日志放大不同源。

## 5.4　写放大

小 value（8 B）相对 4 KiB 页对齐主导放大；$N$ 增大时 logical 上升而 phys 在本负载下保持 28672，故 wa_x100 下降。该现象属页粒度预期，与 xv6 日志放大不同源。

## 5.5　MAP 与 EMUL 对照

表 5.5　$N$=32 时 EMUL 与 MAP

| mode | median_pmfs | median_xv6 | ratio×100 | wa_x100 |
|---|---|---|---|---|
| EMUL | 35830 | 33130730 | 92466 | 2205 |
| MAP | 26477 | 23651219 | 89327 | 2205 |

若 EMUL/MAP 同量级，可推断评测瓶颈主要在算法/提交路径，而非 EMUL 假缓冲主导结果。EMUL 仍**不**代表真 NVDIMM 延迟。

## 5.6　实现难点与失败史

下列踩坑用于证明系统是「调出来的」，并可复核。

**P0 启动栈溢出**　`main()` 跑在原 4 KiB/hart 的 `stack0` 上；自测栈上放置多页缓冲导致溢出，污染邻近内存。修复：页缓冲改 `static`；`stack0` 扩至 16 KiB/hart。

**P1 `rdcycle` 非法指令**　`timerinit` 未开放 `CY` 时，S 态 `rdcycle` 触发 `kerneltrap`。修复：改用已允许的 `r_time()`，并在论文中不作墙钟 $\mu$s 解读。




图 5.3　$N$=32 时 PMFS-KV 在 EMUL 与 MAP 下的中位数延迟。同量级表明瓶颈主要在软件提交路径。

**P2 QEMU NUMA / RAM 尺寸不匹配**　仅配置 160 M 文件后端而默认 $-m$ 仍为 128 M 时，QEMU 立即退出，契约表现为超时。修复：文件后端启动同步 $-m$ 160M。

**P3 MAP 在 $-m$ 128M 下写 PMEMBASE**　无物理后备窗口上的写探测导致 store fault。修复：仅 `-DPMEM_MAP` 时映射并探测。

**P4 Bench 过早杀进程截断契约行**　匹配到 `BENCH_PASS` 子串即杀 QEMU，导致字段截断。修复：等待 `median_xv6=` / `phys=` / `wa_x100=` 齐全。

## 5.7　局限与威胁效度

1. QEMU 非真 NVDIMM；附录给出扩展路径但不喧宾夺主。
2. 性能对比 API 异构；结论限于量级说明。
3. 薄 POSIX 仅为 hash→KV shim，不代表文件语义完备性。

## 5.8　本章小结

尖刺（契约套件）+ 支撑柱（存储核 / PMEM2）+ 可复核踩坑，构成实验章叙事主线；性能图服务于量级与写放大机制说明，而非绝对公平微基准夺冠。

# 第 6 章　结论与展望

## 6.1　工作总结

本文在 xv6-riscv 上设计并实现了并行于根文件系统的字节寻址键值引擎 PMFS-KV，覆盖 EMUL / MAP / PMEM2 三种后端，落地双槽提交、不可变 run、可观测 B3 与量化索引，并构建了以 `ONBOX_PMFS_*` 为核心的可机器判定崩溃与掉电契约套件。

主要结论如下：

1. **方法学：**在教学操作系统上，可机器判定的契约套件比「再实现一套双槽结构」更具不可替代性；正确性可用一行串口与 CI 复现。
2. **系统：**双槽 SB + seal 边界能够表达未提交不可见与半写可检测；写放大可由 wa_x100 观测，且小 value 页对齐放大属预期。
3. **实验：**在故意不对等的 API 下，PMFS-KV 相对 xv6 小文件 `+sync` 呈量级延迟优势；EMUL 与 MAP 同量级表明瓶颈主要在软件提交路径。

## 6.2　不足

真物理 NVDIMM、完整 POSIX 文件层、多核并发与更丰富的压缩/合并策略均未纳入主线。性能数字依赖相对时间单位与 QEMU，外推需谨慎。

## 6.3　展望

- 将契约阶段码扩展到更多故障注入点（中途 kill、部分页损坏）；
- 在附录路线指引下对接真实 PMEM/NVDIMM 平台做延迟校准；
- 在不破坏尖刺的前提下，可选增强索引与多 run 合并策略的可观测性。

答辩一句话总结：**量级优势来自 seal 对小文件 `+sync` 的架构差；不可替代点是教学 OS 上可机器判定的崩溃/掉电契约套件**。

# 参考文献


[1] Burton H. Bloom. Space/time trade-offs in hash coding with allowable errors. *Communications of the ACM*, 13(7):422–426, 1970.

[2] Jeremy Condit, Edmund B. Nightingale, Christopher Frost, Engin Ipek, Benjamin C. Lee, Doug Burger, and Derrick Coetzee. Better I/O through byte-addressable, persistent memory. In *Proceedings of the ACM SIGOPS 22nd Symposium on Operating Systems Principles (SOSP)*, pages 133–146. ACM, 2009. 提出 BPFS.

[3] Russ Cox, M. Frans Kaashoek, and Robert Morris. *xv6: a simple, Unix-like teaching operating system*. MIT CSAIL, 2022. RISC-V edition; https://pdos.csail.mit.edu/6.1810/.

[4] Subramanya R. Dulloor, Sanjay Kumar, Anil Keshavamurthy, Philip Lantz, Dheeraj Reddy, Rajesh Sankaran, and Jeff Jackson. System software for persistent memory. In *Proceedings of the Ninth European Conference on Computer Systems (EuroSys)*, pages 1–15. ACM, 2014. 提出并实现 PMFS；EuroSys 论文题名为 System Software for Persistent Memory.

[5] Youngjin Kwon, Henrique Fingler, Tyler Hunt, Simon Peter, Emmett Witchel, and Thomas Anderson. Strata: A cross media file system. In *Proceedings of the 26th Symposium on Operating Systems Principles (SOSP)*, pages 460–477. ACM, 2017.

[6] Hai-Kun Liu, Di Chen, Hai Jin, Xiao-Fei Liao, Binsheng He, Kan Hu, and Yu Zhang. A survey of non-volatile main memory technologies: State-of-the-arts, practices, and future directions. *Journal of Computer Science and Technology*, 36(1):4–32, 2021.

[7] QEMU Project. *QEMU Documentation*, 2024. https://www.qemu.org/docs/master/.

[8] RISC-V International. *The RISC-V Instruction Set Manual, Volume II: Privileged Architecture*, 2021. Privileged Spec; https://riscv.org/technical/specifications/.

[9] Russell Sears and Raghu Ramakrishnan. bLSM: A general purpose log structured merge tree. In *Proceedings of the 2012 ACM SIGMOD International Conference on Management of Data*, pages 217–228. ACM, 2012.

[10] Haris Volos, Andres Jaan Tack, and Michael M. Swift. Mnemosyne: Lightweight persistent memory. In *Proceedings of the 16th International Conference on Architectural Support for Programming Languages and Operating Systems (ASPLOS)*, pages 91–104. ACM, 2011.

[11] Jian Xu and Steven Swanson. NOVA: A log-structured file system for hybrid Volatile/Non-volatile main memories. In *14th USENIX Conference on File and Storage Technologies (FAST)*, pages 323–338, Santa Clara, CA, 2016. USENIX Association.

[12] 作者. Aurora：量化索引与查询缓存（作者前序原生项目）. 未公开发表设计文档与实现, 2024. 设计约束：键量化、二值 posting、查询 LRU；代码不并入本仓库.

[13] 作者. FCS：嵌入式耐久键值存储引擎（作者前序原生项目）. 未公开发表设计文档与实现, 2024. 设计约束：双槽超级块、不可变 run、B1/B2/B3、写放大计量；代码不并入本仓库.

[14] 作者. CXC/OS 工程化契约验收手法. 作者相关工程实践, 2025. ONBOX 串口契约思想；本课题重写为 ONBOX_PMFS_*.

# 第 A 章　复现命令与扩展说明

## A.1　一键契约与评测

在仓库根目录（WSL）执行：

```
make contract           # EMUL 总闸 -> ONBOX_PMFS_PASS
make contract-pmem      # MAP
make contract-pmem2     # 文件后端掉电二次启动
make bench-sweep        # N=8/16/32 中位数，回填 docs/BENCH.md
```

宿主解析脚本位于 `tools/contract_pmfs.py`、`tools/contract_pmem2.py` 与 bench 相关脚本。

## A.2　关于真 NVDIMM

主线以 QEMU 窗口与文件后端验证语义与契约。若需真 NVDIMM：在具备硬件与内核/固件支持的平台上，将 MAP 窗口替换为实际持久区映射，并重新校准延迟与 `pmem_persist` 屏障语义。该路径不改变契约阶段码表的方法学，但会影响绝对延迟数字；故正文不以其为依赖。

## A.3　论文 PDF 编译

```
cd thesis/latex
make          # xelatex + bibtex + xelatex x2
```

要求：TeX Live（含 `ctex`、`pgfplots`）、Noto CJK 字体。封面姓名/学院等宏可在 `main.tex` 中替换为学校正式模板。

# 致　谢

感谢指导教师在选题、系统边界与论文表述上的悉心指导。感谢教学操作系统 xv6 与 RISC-V / QEMU 开源社区提供的可读代码与实验平台。感谢课程与实验室同学在讨论、复现与答辩准备中的帮助。

本课题将工程验收（可机器判定契约）置于与数据结构同等重要的位置；文中踩坑记录旨在便于后来者复核。文责自负，疏漏之处恳请批评指正。